ΕΘΝΙΚΟ ΜΕΤΣΟΒΙΟ ΠΟΛΥΤΕΧΝΕΙΟ

ΣΧΟΛΗ ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ ΚΑΙ ΜΗΧΑΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ

6ο Εξάμηνο, Βάσεις Δεδομένων
Εξαμηνιαία Εργασία

Επιμέλεια:

- Παλαιοκώστας Μάριος Ιωάννης, 03122205
- Παναγιωταράκος Αλέξιος, 03122200
- Ρούσσος Φίλιππος Νικόλαος, 03122118

A.1 ER Diagram

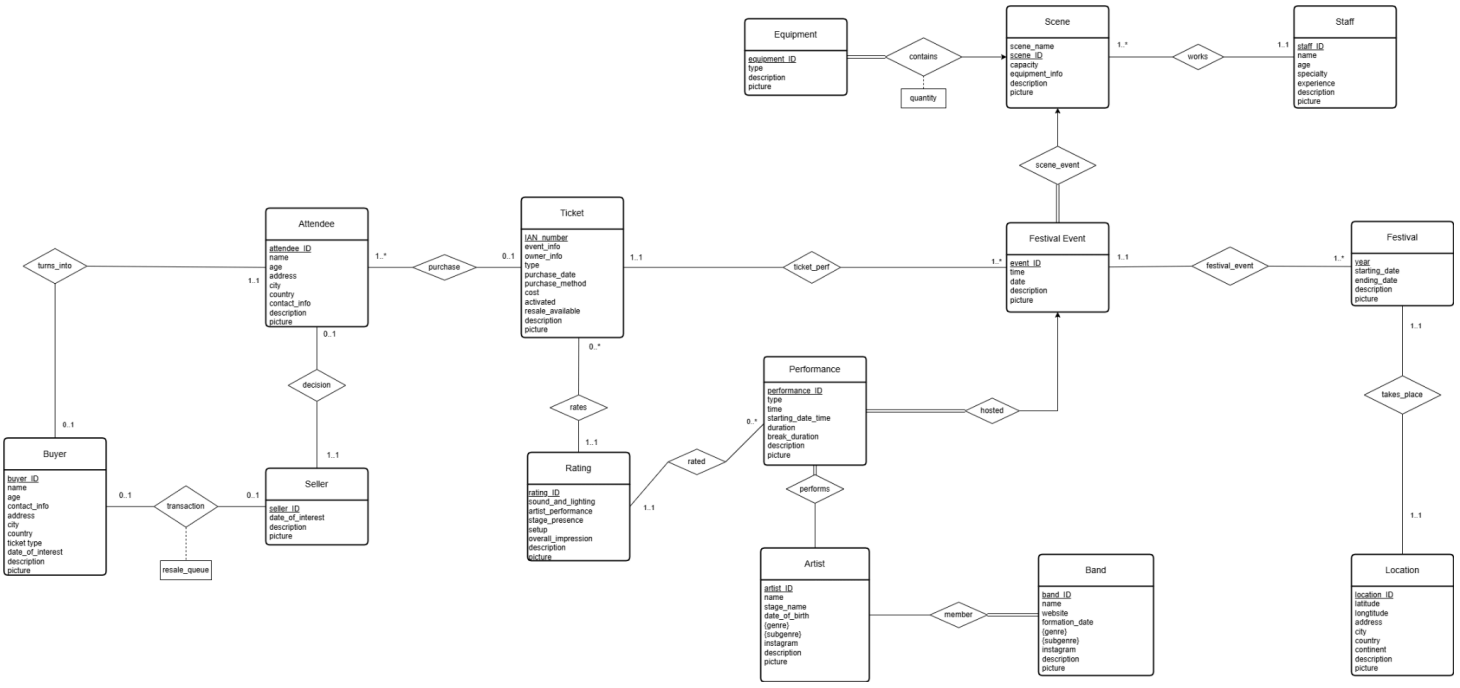

Σχεδιάσαμε το ER diagram μέσω της εφαρμογής draw.io το διάγραμμα επίσης βρίσκεται στο αρχείο pdf ER_music_festival.

Τα Primary Keys είναι τα υπογραμμισμένα στοιχεία σε κάθε table. Τα στοιχεία genre, subgenre που εμφανίζονται στα band, artist έχουν τοποθετηθεί σε άγκιστρα καθώς μπορεί μια μπάντα ή ένας καλλιτέχνης να παίζουν πολλά είδη/υποείδη. Για την σύνδεση του εξοπλισμού με την σκηνή υλοποιήσαμε ένα junction table που επίσης περιέχει την ποσότητα του εξοπλισμού. Για την υλοποίηση του transaction που συνδέει buyer,seller , δημιουγήσαμε μία ξεχωριστή οντότητα ticket_transaction στο sql schema για να καταγράφεται η αγοραπωλησία των εισιτηρίων μέσω του procedure ProcessAllResaleTransactions.

A.2 Relational Diagram

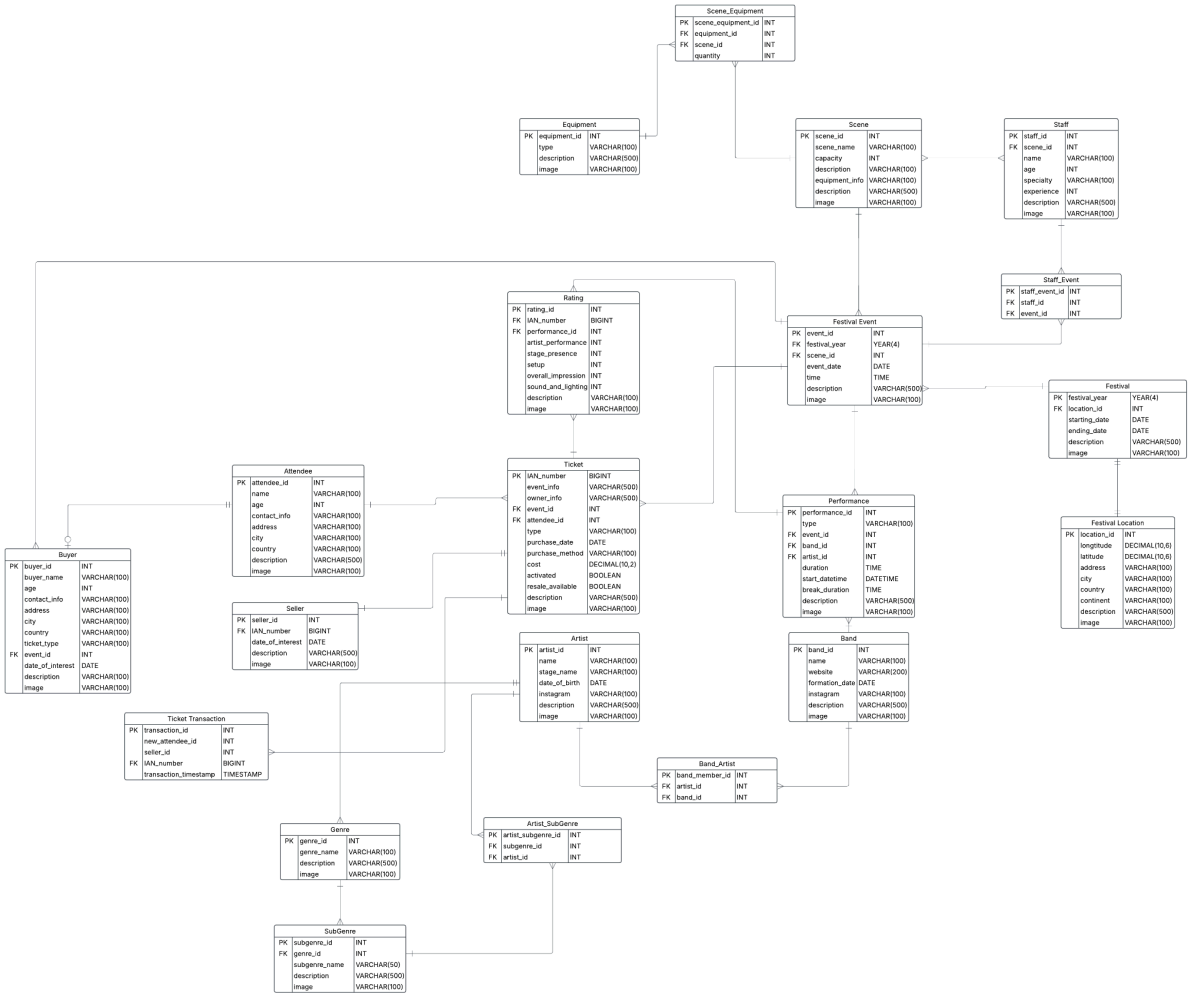

Σχεδιάσαμε το relational diagram μέσω της εφαρμογής Lucidchart το διάγραμμα επίσης βρίσκεται στο pdf Relational Diagram Music Festival.

Σε κάθε many-to-many relationship υλοποιήσαμε junction tables για να μετατρέψουμε κάθε many-to-many σε δύο one-to-many (κάθε εγγραφή του ενός πίνακα να σχετίζεται με πολλές εγγραφές του άλλου πίνακα και αντίστροφα), έτσι ο ενδιάμεσος πίνακας παίρνει τα primary keys των entities που συνδέει δημιουργώντας ένα καινούργιο primary key για κάθε πιθανό συνδυασμό τους.

Όσον αφορά το table buyer τα στοιχεία που περιέχει είναι όμοια με του attendee καθώς όταν καλείται το procedure του resale queue οι αγοραστές που βρίσκουν το επιθυμητό τους εισιτήριο εισάγονται στο table attendee ενώ διαγράφονται από το table των buyers.

Το table ticket_transaction αποτελεί πίνακα για την καταγραφή αγορών-πωλήσεων. Το attribute new_attendee_id είναι το attendee_id που έχει λάβει ο εκάστοτε αγοραστής.

Α.2.1 Περιορισμοί

Για ευκολία, στα junction tables και για άλλες ορισμένες οντότητες έχουμε επιλέξει να ορίσουμε ως primary key ένα νέο attribute {table_name}_id αντί για την ένωση πολλαπλών foreign keys.

Έχουμε εισάγει τους εξής περιορισμούς στα foreign keys:

- `ON DELETE RESTRICT ON UPDATE NO ACTION`

Το `ON DELETE RESTRICT` απαγορεύει την διαγραφή ενός στοιχείου του πίνακα “γονέα” αν υπάρχουν εξαρτώμενα στοιχεία στον τρέχον πίνακα.

Το `ON UPDATE NO ACTION` δεν επιτρέπει την ενημέρωση της τιμής στον πίνακα “γονέα”.

Από την εκφώνηση προκύπτουν ορισμένα constraints που συμπεριλάβαμε με την μορφή CHECKS στα αντίστοιχα tables. Συγκεκριμένα:

- Στο scene `CHECK(capacity > 0)` που εξασφαλίζει μια υπαρκτή χωρητικότητα της σκηνής
- Στο festival `CHECK (ending_date >= starting_date)` για έγκυρες ημερομηνίες διεξαγωγής του φεστιβάλ
- Στο performance `CHECK (duration < 180)` για διάρκεια εμφάνισης μικρότερη των 3 ωρών, `CHECK (break_duration >= 5 AND break_duration <= 30)` για διάρκεια διαλείμματος μεταξύ των εμφανίσεων 5-30 λεπτά, `CHECK ((artist_id IS NOT NULL AND band_id IS NULL) OR (artist_id IS NULL AND band_id IS NOT NULL))` για να ελέγχουμε ότι εμφανίζεται μπάντα ή σόλο καλλιτέχνης.
- Στο ticket `CHECK(activated = FALSE or resale_available = FALSE)` έτσι ώστε να μην επιτρέπεται η ταυτόχρονη ενεργοποίηση του εισιτηρίου και η εισαγωγή του στην ουρά μεταπώλησης.

Ακόμη χρησιμοποιήσαμε UNIQUE για να εξασφαλίσουμε την μοναδικότητα συνδυασμών foreign keys σε junction tables και μεταξύ του festival-festival_location για να έχουμε one-to-one relationship.

Για την αντικατάσταση του τύπου δεδομένων ENUM υλοποιήσαμε TRIGGERS για τον έλεγχο τον δεδομένων που εισάγονται ή ενημερώνονται.

- Στις εμφανίσεις, να ανήκουν σε ένα από τα 3 είδη, `'warm up', 'headline', 'Special guest'`

- Το προσωπικό πρέπει να ανήκει σε ένα από τα είδη, `'technicians', 'security personnel', 'support staff'`

- Ο εξοπλισμός πρέπει να ανήκει σε ένα από τα 5 είδη, `'speakers', 'lights', 'microphones', 'consoles', 'special effects'`

- Για τα εισιτήρια, να ανήκουν σε ένα εκ των ειδών `'general admission', 'VIP', 'backstage'`

- Η μέθοδος πληρωμής πρέπει να ανήκει σε ένα από τα πεδία, `'credit card', 'debit card', 'bank deposit'`

Επίσης, υλοποιήσαμε ένα FUNCTION (`check_vip`) για τον έλεγχο οτι τα VIP tickets δεν υπερβαίνουν το 10% της χωρητικότητας της σκηνής. Χρησιμοποιώντας το παραπάνω FUNCTION υλοποιούμε TRIGGERS(`vip_limit_insert/update`) έτσι ώστε μετά από κάθε εισαγωγή και ενημέρωση στοιχείων στον πίνακα ticket να ελέγχει τον αριθμό των VIP.

Σχετικά με το staff έχουμε ένα PROCEDURE (`CheckStaffRequirements`) για τον έλεγχο της πληρότητας προσωπικού σε κάθε event και το οποίο μας επιστρέφει το υπάρχον και το ζητούμενο προσωπικό σε όσα event δεν πληρούν τις προυποθέσεις. Επιπλέον, έχουμε TRIGGER (`staff_event_check_before_delete/update`) που με κάθε διαγραφή και ενημέρωση προσωπικού ελέγχει ότι πληρούνται οι απαιτούμενες συνθήκες (5% της χωρητικότητας ο αριθμός του προσωπικού ασφαλείας και 2% για το βοηθητικό προσωπικό).

Επιπλέον, υπάρχει TRIGGER (`rating_activated_ticket_check`) για τον έλεγχο της εγκυρότητας των αξιολογήσεων. Το TRIGGER εξετάζει 2 βασικα σημεία:

1) Αν το εισιτήριο που αντιστοιχεί το IAN number είναι activated
2) Αν το εισιτήριο αυτό σχετίζεται με το ίδιο event στο οποίο ανήκει και η παράσταση που αξιολογείται.

TRIGGER (`performance_enforce_rules_before_insert/update`) επίσης έχει υλοποιηθεί για τον έλεγχο του ορίου συμμετοχής κάθε καλλιτέχνη (μέσω του FUNCTION `CheckConsecutiveYears`) και της παράλληλης εμφάνισης του σε άλλη σκηνή (μέσω του FUNCTION `CheckSimultaneousPerformance`).

Τέλος υπάρχει TRIGGER (`after_seller_insert_update_ticket`) το οποίο είναι υπεύθυνο να θέσει το status του εισιτηρίου κάθε πωλητή σε available for resale κατά την εισαγωγή του στο table.

Το Resale Queue υλοποιείται μέσω του procedure ProcessAllResaleTransactions. Καλώντας το procedure και εφόσον υπάρχουν buyers που ενδιαφέρονται για τα εισιτήρια των sellers πραγματοποιούνται ολες οι συναλλαγες με μια κλήση. Το procedure ξεκινάει εντοπίζοντας των πιο παλιο πωλητή και ψάχνει τον παλαιότερο αγοραστή που ενδιαφέρεται για το εισιτήριο. Αν δεν βρει κάποιον προχωράει στον επόμενο seller. Όταν υπάρχει match τότε δημιουργείται ένας καινούριος attendee και τα στοιχεία του αγοραστή καταχωρούνται στο table αυτό. Ο buyer και ο seller διαγράφονται από τα αντίστοιχα tables και η διαδικασία επαναλαμβάνεται. Τελικά καταγράφονται όλες οι συναλλαγές στο Ticket Transaction Table.

A.2.2 Ευρετήρια

Κατά τον ορισμό των indices επικεντρωθήκαμε στα foreign keys και attributes που εμφανίζονται περισσότερο στα queries (Δεν ορίσαμε indices για τα primary keys καθώς δημιουργούνται αυτόματα. Ομοίως, τα foreign keys ορίζονται και αυτά αυτόματα, παρόλα αυτά παραθέτουμε ενδεικτικά τα πιο σημαντικά). Θέσαμε ένα ελάχιστο όριο των 2 queries στα οποία εμφανίζεται το attribute για να το κάνουμε index, έτσι ορίσαμε τα:

```
- idx_staff_specialty ON staff(specialty)
- idx_festival_event_date ON festival_event(event_date)
- idx_subgenre_genre_id ON subgenre(genre_id)
- idx_band_artist_band_id ON band_artist(band_id)
- idx_performance_event_id ON performance(event_id)
- idx_festival_location_id ON festival(location_id)
- idx_staff_event_staff_id ON staff_event(staff_id)
- idx_artist_subgenre_artist_id ON artist_subgenre(artist_id)
- idx_festival_event_festival_year ON festival_event(festival_year)
```

Αποφύγαμε την δημιουργία περαιτέρω indices καθώς επιβαρύνουν τις λειτουργίες εγγραφής, ενημέρωσης και διαγραφής. Επίσης, αν και αρχικά είχαμε συμπεριλάβει τα 2 παρακάτω composite indices δεν τα έχουμε στην τελική υλοποίηση καθώς χρησιμοποιήθηκαν σπάνια:

```
- idx_ticket_event_purchase ON ticket (event_id, purchase_method);
- idx_perf_type_event ON performance (performance_type, event_id);
```

DDL και DML scripts

Για το κομμάτι του DDL υλοποιήσαμε με την σειρά τα αρχεία festival_database.sql (schema του database με τα αντίστοιχα drops πριν από κάθε table για ευκολία κατά την εισαγωγή του στο RDBMS), procedures.sql (που περιέχει τα triggers, functions, procedures) και indices.sql (τα απαραίτητα ευρετήρια). Όσον αφορά το DML, για την δημιουργία των fake data (fake_data.sql) χρησιμοποιήθηκε LLM που έφτιαξε το κατάλληλο python script, με χρήση της βιβλιοθήκης faker. Τέλος, υλοποιήσαμε τα queries.

B. Queries

Τα queries βρίσκονται σε αριθμημένα αρχεία .sql με το αντίστοιχο αποτέλεσμα σε αριθμημένο αρχείο .txt

Για το query 4 χρησιμοποιούμε τον δείκτη idx_rating_1 ON rating(performance_id, overall_impression, artist_performance). Ο πρώτος πίνακας είναι με force ο δεύτερος χωρίς τον δείκτη.

id	select_type	table	type	possible_keys	key	key_len	ref	rows	r_rows	filtered	r_filtered	Extra
1	PRIMARY	A	const	PRIMARY	PRIMARY	4	const	1	*NULL*	100.00	*NULL*	
1	PRIMARY	<derived2>	ALL	*NULL*	*NULL*	*NULL*	*NULL*	17	16.00	100.00	100.00	
1	PRIMARY	R	ref	idx_rating_1	idx_rating_1	4	API.performance_id	1	0.88	100.00	100.00	Using index
2	DERIVED	p	ref	artist_id	artist_id	5	const	1	1.00	100.00	100.00	Using index
3	UNION	ba	ref	artist_id,band_id	artist_id	4	const	2	2.00	100.00	100.00	Using index
3	UNION	p	ref	band_id	band_id	5	festival_database.ba.band_id	8	7.50	100.00	100.00	Using index
NULL	UNION RESULT	<union2,3>	ALL	*NULL*	*NULL*	*NULL*	*NULL*	*NULL*	16.00	*NULL*	*NULL*	

id	select_type	table	type	possible_keys	key	key_len	ref	rows	r_rows	filtered	r_filtered	Extra
1	PRIMARY	A	const	PRIMARY	PRIMARY	4	const	1	*NULL*	100.00	*NULL*	
1	PRIMARY	<derived2>	ALL	*NULL*	*NULL*	*NULL*	*NULL*	17	16.00	100.00	100.00	
1	PRIMARY	R	ref	performance_id	performance_id	4	API.performance_id	1	0.88	100.00	100.00	
2	DERIVED	p	ref	artist_id	artist_id	5	const	1	1.00	100.00	100.00	Using index
3	UNION	ba	ref	artist_id,band_id	artist_id	4	const	2	2.00	100.00	100.00	Using index
3	UNION	p	ref	band_id	band_id	5	festival_database.ba.band_id	8	7.50	100.00	100.00	Using index
NULL	UNION RESULT	<union2,3>	ALL	*NULL*	*NULL*	*NULL*	*NULL*	*NULL*	16.00	*NULL*	*NULL*	

Από τους παραπάνω πίνακες βλέπουμε ότι η χρήση του νέου index δεν επιταχύνει ούτε επιβραδύνει το query, πράγμα που επιβεβαιώνεται και από τα παρακάτω traces.

Ελέγχοντας τα αντίστοιχα traces χρησιμοποιώντας τις εντολές

```
SET optimizer_trace="enabled=on";
```

Και ύστερα

```
SELECT * FROM INFORMATION_SCHEMA.OPTIMIZER_TRACE;
```

Με force index:

"rows_for_plan": 16,

"cost_for_plan": 14,

"estimated_join_cardinality": 16

Ενώ αρχικά:
"rows_for_plan": 16,
"cost_for_plan": 14,
"estimated_join_cardinality": 16

Για το query 6 επιλέξαμε Force Index idx_ticket_attendee_activated ON ticket (attendee_id, activated). Το query φιλτράρει άμεσα βάσει attendee_id = 1 και activated = TRUE οπότε συνδυάζοντας αυτα τα δύο πεδία στο index εντοπίζουμε μόνο τις εγγραφές του επισκέπτη που έχουν ενεργοποιηθεί αποφεύγοντας να σαρώσουμε όλο τον πίνακα.

id	select_type	table	type	possible_keys	key	key_len	ref	rows	r_rows	filtered	r_filtered	Extra
1	SIMPLE	T	ref	idx_ticket_attendee_activated	idx_ticket_attendee_activated	5	const,const	2	2.00	100.00	100.00	Using temporary; Using filesort
1	SIMPLE	FE	eq_ref	PRIMARY	PRIMARY	4	festival_database.T.event_id	1	1.00	100.00	100.00	Using index
1	SIMPLE	R	ref	IAN_number,performance_id	IAN_number	8	festival_database.T.IAN_number	1	1.00	100.00	100.00	
1	SIMPLE	P	eq_ref	PRIMARY,event_id	PRIMARY	4	festival_database.R.performance_id	1	1.00	100.00	100.00	Using where

id	select_type	table	type	possible_keys	key	key_len	ref	rows	r_rows	filtered	r_filtered	Extra
1	SIMPLE	FE	index	PRIMARY	festival_year	1	*NULL*	99	99.00	100.00	100.00	Using index; Using temporary; Using filesort
1	SIMPLE	P	ref	PRIMARY,event_id	event_id	4	festival_database.FE.event_id	1	1.86	100.00	100.00	Using index
1	SIMPLE	R	ref	IAN_number,performance_	performance_id	4	festival_database.P.performance_id	1	0.67	100.00	100.00	
1	SIMPLE	T	eq_ref	PRIMARY,event_id	PRIMARY	8	festival_database.R.IAN_number	1	1.00	100.00	1.63	Using where

Όπως φαίνεται από τους παραπάνω πίνακες (συγκεκριμένα στις στήλες rows, r_rows) με την χρήση του index σαρώνουμε 2 rows έναντι των 99 rows που σαρώνουμε χωρίς την χρήση του index. Αφού δημιουργήσουμε το index και τρέξουμε το query χωρίς FORCE INDEX βλέπουμε ότι επιλέγεται αυτόματα το index υποδεικνύοντας ότι το νέο index είναι πιο αποδοτικό.

Ελέγχοντας τα αντίστοιχα traces χρησιμοποιώντας τις εντολές
```
SET optimizer_trace="enabled=on";
```
Και ύστερα
```
SELECT * FROM INFORMATION_SCHEMA.OPTIMIZER_TRACE;
```

Με force index:
"best_join_order": ["T", "FE", "R", "P"]
"rows_for_plan": 184,
"cost_for_plan": 40.8,

Ενώ αρχικά:
"best_join_order": ["FE", "P", "R", "T"]
"rows_for_plan": 200,
"cost_for_plan": 725,